



Propuesta Proyecto de Titulación

Sistema de Recomendación para riego, basado en
Inteligencia Artificial y Procesamiento del Lenguaje
Natural.

Ingeniería Civil en Computación

Universidad de Talca

02-09-2025

Estudiante: Claudio Hernández

Profesores Guías: Fernando Fuentes, Rodrigo Pavez

ÍNDICE GENERAL



Lista de Figuras	1
Lista de Cuadros	1
1. Descripción Del problema	2
1.1. Contexto	2
1.2. Definición del problema	2
1.3. Trabajo Relacionado	3
1.4. Propuesta de Solución	3
1.4.1. Sobre la recopilación de datos necesarios	3
1.4.2. Sobre el análisis y reglas	4
1.4.3. Sobre el procesamiento del lenguaje natural	5
1.4.4. Sobre la recepción de la información	5
1.4.5. Sobre Módulos gráficos	5
1.5. Herramientas a utilizar	5
2. Objetivos	8
2.1. Objetivo General	8
2.2. Objetivos Específicos	8
3. Alcances	8
3.0.1. Lo que SÍ se piensa hacer	8
 3.0.2. Lo que NO se piensa hacer	9
4. Metodología	9
4.1. Metodologías de desarrollo	9
4.1.1. Scrumban	9
4.2. Metodologías de evaluación del proyecto	9
4.2.1. Pruebas de Caja negra	10
4.2.2. Efectividad	10
4.2.3. Usabilidad y Experiencia	10
5. Plan de Trabajo	10
5.1. Etapas del proyecto	10
5.1.1. Etapas del plan de trabajo	10
5.1.2. Tareas por objetivo específico	11
Bibliografía	12
Lista de Figuras 	
1.1. Arquitectura de Recuperación Aumentada por Generación (RAG) propues- ta por AWS [12].	7
1.2. Flujo propuesto del sistema	7
Lista de Cuadros	
1.1. Cobertura de variables FAO-56 en APIs.	6

DESCRIPCIÓN DEL PROBLEMA



1.1 Contexto

Como es bien sabido, la agricultura nacional como internacional pasa por desafíos vinculados a la escasez hídrica. La digitalización del Agro se convierte entonces en una herramienta clave para **enfrentar estos problemas**, aportando soluciones innovadoras que permitan ayudar a los agricultores. Gran parte de la agricultura alcanza niveles de ineficiencia hídrica con un rango **del 50 % a 40 %**, en especial la pequeña agricultura, la cual tiene acceso limitado a este recurso, siendo un actor de alta vulnerabilidad [1]. Numerosos intentos se han hecho para **abordar este problema**, provenientes de áreas relacionadas al Internet de las Cosas (IoT), sin embargo con el estallido de las tecnologías de inteligencia artificial, surge la pregunta sobre cómo se puede utilizar estas herramientas para aportar a las soluciones. Es por esto que existen iniciativas relacionadas al uso de modelos de Machine Learning o LLM's para generar sistemas que permitan mejorar el consumo y manejo del agua. Es necesario explicar estos dos modelos para notar sus diferencias y entender el porqué se requiere de un LLM y no un modelo tradicional de ML (Machine Learning). Un modelo ML utiliza el aprendizaje supervisado o no supervisado para entrenar un algoritmo, estos tipos de aprendizaje requieren de una intervención humana para tratar los datos y guiar el aprendizaje, generalmente están enfocados en clasificación, predicción o descubrimiento de patrones en un conjunto de datos, por otro lado un LLM se basa en el aprendizaje profundo, con datos sin estructurar, por lo que elimina una parte de la intervención humana [2]. Este último tipo de modelo, basado en redes neuronales, es más flexible y permite realizar tareas, como responder preguntas, resumir documentos, traducir idiomas y completar oraciones. Dependiendo de la arquitectura estos modelos tienen distintos tamaños (los parámetros que han sido ajustados en el entrenamiento), por ejemplo GPT-3 de OpenAI cuenta con 175 000 millones de parámetros [3]. Existe otro concepto interesante a revisar cuando hablamos de inteligencia artificial conocido como embedding, el cual consiste en representar texto, imágenes o audios como puntos en un espacio vectorial. El embedding es una herramienta fundamental en inteligencia artificial, que ayuda a que los modelos de IA encuentren objetos similares a los almacenados, por lo que es muy útil cuando se necesita crear motores de búsqueda de texto e imágenes, chatbots, sistemas de recomendación, entre otras aplicaciones [4]. Sin embargo, se debe ser cautelosos a la hora del uso de estas herramientas, pues el consumo eléctrico que se demanda para modelos de inteligencia artificial más capaces como Gemini o ChatGPT se equipara anualmente al consumo de países pequeños, debido a la alta demanda que generan sus API's (Interfaz de Programación de Aplicaciones)[5]. Junto a esto, surge entonces el desafío de encontrar una solución balanceada, que permita el ahorro de agua al regar sin dejar de ser sustentable.



1.2 Definición del problema

Chile, al igual que en el resto del mundo, se enfrenta a la problemática de la escasez hídrica, es por esto que la gestión de este recurso surge como una necesidad, en la actualidad existen dispositivos capaces de automatizar procesos como el riego, permitiendo administrar mejor el consumo de agua, sin embargo dichos dispositivos muchas veces im-

plican altos costos, lo cual se traduce en que pequeños y medianos agricultores no puedan acceder a as herramientas. Dada la necesidad y la falta de acceso a soluciones, surge una oportunidad de proveer un sistema que sea capaz de manejar información relacionada a cultivos y datos meteorológicos, con el fin de generar recomendaciones de riego a agricultores .

1.3 Trabajo Relacionado

Actualmente los LLM tienen un impacto significativo en la industria agrícola, desde consultores hasta identificadores de plagas en plantas [6], gran parte de ellos parten de un LLM ya entrenado para uso general, pero son sometidos a un **fine-tuning** para darles más conocimiento sobre el área que se necesita específicamente, **como esfuerzos realizados**, a día de hoy se pueden observar modelos como AgriLLM, el cual parte de la base de Llama3.2 ~~y~~ fue entrenado especialmente para resolución de consultas para granjeros de la India, los cuales no pueden acceder a una consultoría de forma temprana [7].

Otros enfoques abordan el entrenar algoritmos de inteligencia artificial como árboles de decisión o redes neuronales para realizar una predicción sobre la humedad del suelo con propósito de planificar el riego, utilizando variables de sensores locales y clima, implementando un sistema que termina por enviar mensajes a un agricultor dependiendo de la situación, vía aplicación móvil[8].

1.4 Propuesta de Solución

La hipótesis **en cuestión es simple**, un sistema de recomendación basado en IA, mejoraría la eficiencia del uso del agua, **mejorando** la toma de decisiones para agricultores. Se propone como solución un sistema de recomendación de riego, que implemente algoritmos que hagan uso de inteligencia artificial, para procesar información meteorológica, con los cuales se pueda generar una recomendación para **mejorar** el uso del agua para riego con explicación contextualizada a través de medios de mensajerías establecidos, de esta forma pequeños y medianos agricultores tendrían una herramienta accesible y adecuada a su entorno en concreto, para **mejorar** su consumo de agua. La solución debe comprender la recopilación de datos, análisis y creación de reglas, procesamiento de lenguaje natural y envío de mensajes. Cabe destacar que dichos LLMs estarían alojados de forma local, por lo que se tendrá que hacer pruebas para seleccionar el más adecuado, sin embargo esto nos deja ver que deberá ser un modelo mucho más pequeño **que los masificados** en internet, lo cual resulta útil para el propósito del proyecto, puesto que un modelo pequeño pero especializado en un área puede llegar a reducir en un 90 % el consumo de energía necesario [5]. .

1.4.1 Sobre la recopilación de datos necesarios

En orden de poder generar las recomendaciones, es necesario poder mencionar las siguientes variables: humedad del suelo, el tipo de cultivo y su etapa, las lluvias o riegos que han habido sobre la zona, la forma de riego, el déficit de agua existente y la demanda de agua de la planta en cuestión. Si bien las lluvias o el tipo de cultivo se puede saber fácilmente y otras mediante consultas a APIs de meteorología, el déficit o la demanda de agua es algo que se debe calcular o por defecto estimar. La Organización de Agricultura y Comida (FAO) cuenta con varios estudios en los cuales se abordan técnicas para calcular o estimar estas variables. Es necesario que el sistema pueda **calcular** la demanda

de agua de la planta para poder **calcular** el déficit acumulado de esta. FAO-56 propone una versión estandarizada de la ecuación Penman-Monteith, la cual permite **calcular** la Evapotranspiración de la planta (ET_0) [9], una variable que representa la cantidad de agua que pierde mediante procesos de evaporación del agua y transpiración de la planta. Por otro lado, en este artículo también se establece la ecuación del balance hídrico [9], la cual permite **calcular** el déficit en base a una ecuación recursiva. Dicho **calculo** sería útil para establecer reglas de riego que puedan ayudar a generar la recomendación final al agricultor. A nivel de programación, existen distintas librerías para hacer estos **cálculos**, en Python por ejemplo, se encuentran las librerías pyET o pyFAO56, si bien ambas demandan distintos tipos de entradas, se puede **establecer un consenso** en las variables a necesitar para estos **cálculos**, las cuales son:

1. Climatológicas

- Temperatura media o máxima y mínima.
- Humedad Relativa (HR) media o máxima y mínima.
- Radiación solar.
- Velocidad del viento a 2m.

2. Espaciales

- Altitud.
- Latitud.

3. Referentes al cultivo

- Tipo de cultivo.
- Forma de riego.
- Tipo del suelo.
- Etapa del cultivo.
- Horas de sol.

Se pretende construir un módulo que se conecte a APIs públicas, para la obtención de las variables anteriores, principalmente las climatológicas, ~~tanto~~ espaciales y las referentes al cultivo se pueden obtener mediante **simples preguntas** y con la ayuda de GPS, algunas otras pueden ser inferidas o deducidas mediante métodos o tablas que FAO-56 provee [9]. De aquí deberá salir la información empaquetada que el sistema necesite para seguir con el flujo de generar una recomendación, además se planea que este módulo cuente con una interfaz de monitoreo, **para visualizar los datos entrantes y el curso del sistema**.

1.4.2 *Sobre el análisis y reglas*

Se pretenden utilizar manuales, guías oficiales de buenas prácticas para el riego y la agricultura como el de la INIA [10], además de la ecuación del balance hídrico [9] para identificar la situación actual, y así con los datos recopilados poder establecer un escenario, por ejemplo con condicionales (If déficit<X Then do Y), este módulo deberá implementar las reglas en base a manuales o derivadas de ecuaciones, además de hacer los cálculos necesarios para poder generar recomendaciones a un nivel técnico, dichas recomendaciones deberán salir empaquetadas a la siguiente fase del sistema.

1.4.3 *Sobre el procesamiento del lenguaje natural*

El módulo de procesamiento del lenguaje natural (PLN) planea incorporar librerías y LLMs locales (y de menor tamaño como 4B o 1B) que permitan, en base a la información que se tiene y las recomendaciones técnicas generadas con las reglas definidas, generar una recomendación entendible para los agricultores con su respectiva explicación. Como entrenar un LLM para esto, es costoso y requiere tiempo para el ajuste fino que se suele requerir, se piensa en una sistema con solución RAG[11], con bases de datos para embeddings como Qdrant, lo que aseguraría precisión a la hora de generar una respuesta con información fiable en base a manuales y aseguraría la posibilidad de escalar la solución a un contexto más local, mediante la suma de documentación técnica, nacional o internacional, de esta forma se logra sustentabilidad y contextualización al no depender de consultas a modelos costosos y generalizados.

1.4.4 *Sobre la recepción de la información*

Por último el módulo de mensajería, este se encargaría de enviar las recomendaciones por un canal establecido, accesible a los agricultores, ya sea vía SMS o redes sociales como Telegram o Whatsapp.

1.4.5 *Sobre Módulos gráficos*

Como algunas variables para las recomendaciones deben ser consultadas por los agricultores, se planea implementar interfaces mínimas, que permitan recopilar información del usuario y pedir las recomendaciones, además del monitoreo del sistema. Las interfaces planeadas son las siguientes:

1. Interfaz de Registro y Login: El sistema contará con registro de usuarios para recordar la información de estos tales como niveles hídricos, ubicación de sus cultivos y etapa de estos, además del tipo de planta.
2. Interfaz Principal: Aquí se podrán guardar mediante selección los cultivos de interés y con ayuda de API's de mapas la ubicación de estos mismos, además de contener la posibilidad de pedir las recomendaciones o dejarlas programadas.
3. Interfaz Monitoreo: Esta interfaz refiere para los administradores del sistema, para que puedan visualizar logs generados por las distintas etapas del sistema, para comprobar el funcionamiento y disponibilidad del sistema.

Todos estos módulos son los mínimos necesarios para que el flujo del sistema opere.

1.5 Herramientas a utilizar

El sistema como tal, necesita de un servidor que se encuentre en constante funcionamiento, distintas opciones existen desde Azure, Google Cloud, o AWS. Se planea arrendar una máquina en alguna de estas instancias para alojar bases de datos y servicios necesarios.

Para el apartado de APIs se pueden encontrar varias relacionadas a meteorología que se pueden valorar acorde a la siguiente tabla:

Cuadro 1.1: Cobertura de variables FAO-56 en APIs.

API	T	RH/Td	$u(z)$	Rs	P	n	Alt	Límite (grat.)
POWER (NASA)	✓	✓	✓ ₂	✓	✓	—	—	—
MeteoSource	✓	✓	✓ ₁₀	✓	✓	—	—	400/d
NOAA CDO/ISD	✓	◦	✓ ₁₀	△	✓	—	—	10k/d
OpenWeather	✓	✓	✓ ₁₀	△	✓	—	—	1k/d
Meteostat	✓	✓	✓ ₁₀	—	✓	✓	✓	500/m
Open-Meteo	✓	✓	✓ ₁₀	✓	✓	✓	✓	10k/d

Leyenda de columnas: T = temperatura del aire [°C]; RH/Td = humedad relativa [$u(z)$ = velocidad del viento a altura z [m·s⁻¹]; Rs = radiación solar global [MJ·m⁻²·día⁻¹]; P = presión atmosférica [kPa]; n = horas de sol [h]; Alt = altitud del emplazamiento [m].

Leyenda de símbolos: ✓ = disponible directo; △ = disponible parcial (según producto/estación); ◦ = deducible a partir de otra variable (p. ej., RH desde Td, u_2 desde u_{10} , P desde Alt); — = no disponible.

En $u(z)$, el subíndice indica la altura del anemómetro (m). Para ajustar $u_{10} \rightarrow u_2$, usar FAO-56: $u_2 \approx 0,748 u_{10}$.

Mediante esta comparativa se puede ver que las APIs más convenientes son Open-Meteo, NOAA y POWER por la cantidad de usos que permiten y los datos que ofrecen, además estos datos se pueden acompañar de APIs de mapas para obtener valores de altitud y latitud. Por completitud y límites de uso, se propone usar Open-Meteo para desarrollar el sistema.

Por otro lado, se pretende trabajar un backend en Python, debido a las librerías que ofrece, como por ejemplo, las librerías para hacer los cálculos de evapotranspiración, mientras que el frontend se propone trabajar con React como framework y lenguajes web como Javascript, HTML y CSS. La base de datos se propone usar PostgreSQL de forma local en la instancia del servidor para almacenar datos de las APIs y de los usuarios. El flujo de la aplicación consiste en conectarse con el frontend para configurar las recomendaciones, dando información de los cultivos y zonas, mediante tecnología GPS y selectores, el backend recopilaría datos y los almacenaría (según la capacidad). En base a las reglas y cálculos necesarios se generarán recomendaciones técnicas considerando las variables recopiladas y procesadas, dicha información deberá pasar por el módulo de procesamiento de lenguaje natural, el que usará modelos LLMs locales (1B o 4B), los que usando la arquitectura RAG, deberán recuperar información técnica relacionada a los cultivos y la recomendación técnica generada desde la información oficial almacenada en la base de datos vectorial, la siguiente figura ilustra la arquitectura RAG típica:




Figura 1.1: Arquitectura de Recuperación Aumentada por Generación (RAG) propuesta por AWS [12].

Para la base de datos vectorial, se propone usar Qdrant de forma local, estableciendo un proceso de búsqueda de información en forma de manuales o bibliografía existente, para ser convertida posteriormente a representación numérica (embeddings) que será almacenada. Con esto se podrá generar una explicación y recomendación simple para el agricultor que será enviada por el canal acordado de mensajería. El flujo de la aplicación está resumido en el siguiente gráfico:




Figura 1.2: Flujo propuesto del sistema

OBJETIVOS

2.1 Objetivo General

Diseñar e implementar un sistema de recomendación de riego **accesible** basado en inteligencia artificial y lenguaje natural para ayudar en la toma de decisiones a agricultores.

2.2 Objetivos Específicos

1. Caracterizar la línea base de consumo de agua de los **agricultores participantes** para establecer puntos de referencia.
2. Desarrollar algoritmos usando modelos de inteligencia artificial capaces de generar recomendaciones **precisas**, considerando condiciones climáticas, características del cultivo y disponibilidad hídrica.
3. Implementar un módulo para el procesamiento de lenguaje natural, que permita traducir recomendaciones técnicas en mensajes claros y comprensibles.
4. Validar la efectividad del sistema, **comparando consumo de agua antes** y después de su uso.
5. Evaluar la efectividad y experiencia de los agricultores, en términos de usabilidad, adopción y satisfacción de la herramienta.

ALCANCES

A continuación se detallan los alcances del proyecto, detallando lo que sí se pretende y no pretende hacer

3.0.1 *Lo que SÍ se piensa hacer*

- Establecer puntos de referencia para el consumo de agua al inicio y finalización del sistema.
- Recopilar reglas que sirvan para generar recomendaciones técnicas, por ejemplo, condicionales If-Else respecto a una variable.
- Crear un sistema dockerizable que viva en servidores, gestionando el flujo de información y procesos. 
- Desarrollar interfaces gráficas mínimas que permitan gestionar información de los usuarios y solicitar recomendaciones.
- Utilizar un módulo de LLM qlocal ue permita analizar los datos recibidos y procesar recomendaciones técnicas, para generar recomendaciones sencillas para agricultores.

- Utilizar canales de mensajería como Telegram, Whatsapp, o SMS para la recepción de las recomendaciones. 
- Evaluar la efectividad del sistema y valoración del usuario
- Utilizar mayormente datos de API's de mapas y de climatología para la recopilación de variables

3.0.2 *Lo que NO se piensa hacer*

- No se pretende entrenar un LLM, si no que usar los existentes con distintas técnicas para ajustarlo a lo necesario.
- El sistema no planea realizar calendarización de riego, solo trabajar con la información histórica.
- No se pretende manipular sensores para recopilación de datos.

METODOLOGÍA

4.1 Metodologías de desarrollo

Dado que el proyecto, establece áreas en las que se tendrá que evaluar el diseño y rendimiento de los módulos y muy probablemente, por la naturaleza del trabajo en el área de la IA, se tendrá que realizar mejoras a dichos módulos. Se propone entonces, para el desarrollo del sistema, la metodología Scrumban, un enfoque ágil que combina prácticas de Scrum y Kanban, documentado por Corey Ladas (2008) [13]. Esta metodología integra la estructura de planificación de Scrum con la flexibilidad y control visual de Kanban.

4.1.1 *Scrumban*

A continuación se detallan sus fases principales considerando sprints de dos semanas:

1. Planificación del ciclo: Se definen las tareas y objetivos para un periodo de 2 a 3 semanas.
2. Tablero de trabajo: Se emplean las columnas *To do*, *In progress*, *En revisión* y *Ready*, estableciendo un límite WIP de máximo 2 tareas en paralelo.
3. Ejecución: Desarrollo de las tareas planificadas dentro de la iteración.
4. Revisión: Evaluación del prototipo o entregable obtenido, aplicando pruebas básicas como caja negra.
5. Ajustes: Corrección de errores y priorización de nuevas tareas para el siguiente ciclo.

4.2 Metodologías de evaluación del proyecto

Se propone que el proyecto cuente con tres vías de evaluación, referentes a las áreas técnicas, efectividad y usabilidad.

4.2.1 Pruebas de Caja negra

Para las pruebas técnicas de software, se propone las pruebas de caja negra, las que permiten evaluar componentes modularizados de código, sin conocer el qué sucede internamente, estas consisten verificar entrada versus salida esperada, lo que permite verificar el flujo del sistema.

4.2.2 Efectividad

Una vez el sistema tenga los componentes necesarios para operar, se tendrá que registrar el consumo de agua actual, de esta forma, se planea evaluar la efectividad comparando el consumo de agua antes y después de implementar el sistema de recomendación, usando los puntos de referencias establecidos con anterioridad.

4.2.3 Usabilidad y Experiencia

Para evaluar la experiencia de los usuarios, se propone realizar encuestas simples para el usuario final, por ello, se planea usar la escala likert, por otro lado, para evaluar la usabilidad se propone usar la escala SUS (System Usability Scale), la que consta de 10 preguntas y fue elaborada por John Brooke en 1986

PLAN DE TRABAJO

5.1 Etapas del proyecto

En esta sección se detalla el plan de trabajo:

5.1.1 Etapas del plan de trabajo

1. Requerimientos y Diseño (1 semana)
 - Levantar requisitos del sistema.
 - Levantar esquema de datos.
 - Definición de zonas pilotos.
2. Recopilación de datos (2 semana)
 - Recopilación de datasets congelados históricos.
 - Caracterización del consumo de agua inicial.
3. Planificación (3 semanas)
 - Revisar documentación FAO y manuales para riego.
 - Definir Reglas para recomendaciones.
 - Implementar historias de usuario en base a requisitos.
 - Creación de Mockups.
 - Configurar entorno de desarrollo y herramientas.

4. Implementación de módulos principales (11 semanas)

- Desarrollo módulo de recopilación constante de datos y almacenamiento de estos.
- Desarrollo módulo de reglas y cálculos para recomendación técnica
- Desarrollo módulo de gestión de usuarios
- Desarrollo módulo de gestión de información de usuario para recomendaciones

5. Implementación de módulos NLP (4 semanas)

- Definir e implementar LLM por elección en base a pruebas de rendimiento
- Implementar Módulo RAG con base de datos vectorial
- Implementar módulo de mensajería

6. Evaluación (2 semanas)

- Aplicar pruebas de caja negra
- Aplicar pruebas de usabilidad (SUS)
- Definir puntos de referencias post-implementación del sistema

7. Conclusión (3 semanas)

- Evaluar puntos de referencias post-implementación del sistema
- Aplicar correcciones y ajustes
- Creación documentación

5.1.2 *Tareas por objetivo específico*

1. Caracterizar la línea base de consumo de agua y productividad de los agricultores participantes para establecer puntos de referencia.
 - a) Etapa 1: Reunión para definir zonas pilotos
 - b) Etapa 2: Consultas periódicas a la API definida para recopilación de información climatológica histórica.
 - c) Etapa 2: Levantar puntos de referencias iniciales sobre consumo de agua.
 - d) Etapa 3: Revisión documentación FAO, para realizar cálculos
 - e) Etapa 6: Levantar puntos de referencias finales sobre consumo de agua.
2. Desarrollar algoritmos usando modelos de inteligencia artificial capaces de generar recomendaciones precisas, considerando condiciones climáticas, características del cultivo y disponibilidad hídrica.
 - a) Etapa 3: Revisión documentación FAO, para realizar cálculos.
 - b) Etapa 3: Recopilar reglas o fórmulas para recomendaciones técnicas, revisando documentación.
 - c) Etapa 4: Implementar las reglas o fórmulas, mediante condicionales y crear sentencias de texto que ayuden al LLM a obtener mayor contexto de la situación.

3. Implementar un módulo para el procesamiento de lenguaje natural, que permita traducir recomendaciones técnicas en mensajes claros y comprensibles.
 - a) Etapa 3: Revisión documentación FAO y manuales.
 - b) Etapa 5: Vectorizar la documentación encontrada para subirla a la base de datos.
 - c) Etapa 5: Buscar o desarrollar pruebas en base a set's de preguntas para evaluar rendimiento de los modelos LLM.
 - d) Etapa 5: Probar distintos LLM con distintos tamaños en arquitectura RAG para evaluar el rendimiento.
4. Validar la efectividad del sistema, comparando consumo de agua antes y después de su uso.
 - a) Etapa 7: Comparar las métricas de referencia de consumo de agua (inicial versus final)
5. Evaluar la efectividad y experiencia de los agricultores, en términos de usabilidad, adopción y satisfacción de la herramienta.
 - a) Etapa 6: Generar las pruebas SUS para evaluar usabilidad

BIBLIOGRAFÍA

- [1] Opia.CL: Observatorio Para La Innovación Agraria, Agroalimentaria Y Forestal, *El cambio climático y los recursos hídricos de Chile*, https://opia.fia.cl/601/articles-91835_archivo_01.pdf, Consultado en 2025, n.d.
- [2] IBM Think, *¿Qué es machine learning?* <https://www.ibm.com/mx-es/think/topics/machine-learning>, Consultado el 18 de septiembre de 2025, 2025.
- [3] Amazon Web Services (AWS), *¿Qué es un LLM (modelo de lenguaje de gran tamaño)?* <https://aws.amazon.com/es/what-is/large-language-model/>, Consultado el 18 de septiembre de 2025, 2025.
- [4] J. Barnard, *¿Qué es embedding?* <https://www.ibm.com/mx-es/think/topics/embedding>, Consultado el 18 de septiembre de 2025, dic. de 2023.
- [5] UNESCO. “Modelos de lenguaje grandes de IA: un nuevo informe revela cómo reducir el consumo de energía en un 90 %,” UNESCO. (2025), dirección: <https://www.unesco.org/es/articles/modelos-de-lenguaje-grandes-de-ia-un-nuevo-informe-revela-como-reducir-el-consumo-de-energia-en-un> (visitado 09-09-2025).
- [6] T. A. Shaikh, T. Rasool, K. Venington y S. M. Yaseen, “The role of large language models in agriculture: harvesting the future with LLM intelligence,” en, *Prog. Artif. Intell.*, dic. de 2024.
- [7] K. Didwania, P. Seth, A. Kasliwal y A. Agarwal, *AgriLLM: Harnessing Transformers for Farmer Queries*, 2024. arXiv: [2407.04721 \[cs.CL\]](https://arxiv.org/abs/2407.04721). dirección: <https://arxiv.org/abs/2407.04721>.
- [8] A. Goap, D. Sharma, A. K. Shukla y C. Rama Krishna, “An IoT based smart irrigation management system using Machine learning and open source technologies,” en, *Comput. Electron. Agric.*, vol. 155, págs. 41-49, dic. de 2018.

- [9] R. G. Allen, L. S. Pereira, D. Raes y M. Smith, *Crop Evapotranspiration: Guidelines for Computing Crop Water Requirements* (FAO Irrigation and Drainage Paper). Rome, Italy: FAO - Food y Agriculture Organization of the United Nations, 1998, vol. 56, ISBN: 92-5-104219-5.
- [10] R. López-Olivari, ed., *Manejo y uso eficiente del agua de riego intrapredial para el sur de Chile: Conceptos y consideraciones básicas en métodos y programación de riego para optimizar el recurso hídrico* (Boletín INIA 340). Chile: Instituto de Investigaciones Agropecuarias (INIA), 2019.
- [11] P. Lewis, E. Perez, A. Piktus et al., *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*, 2021. arXiv: [2005.11401 \[cs.CL\]](https://arxiv.org/abs/2005.11401). dirección: <https://arxiv.org/abs/2005.11401>.
- [12] Amazon Web Services. “¿Qué es generación aumentada por recuperación (RAG)?” Accedido: 16 septiembre 2025. (2025), dirección: <https://aws.amazon.com/es/what-is/retrieval-augmented-generation/>.
- [13] C. Ladas, “Scrumban - Essays on Kanban Systems for Lean Software Development,” ene. de 2009.